



POLITECHNIKA ŚLĄSKA
WYDZIAŁ INŻYNIERII BIOMEDYCZNEJ

Praca dyplomowa magisterska

Szacowanie wielkości naczynia w badaniach USG

Autor: inż. Agata Momot

Kierujący pracą: dr Jan Juszczyk

Gliwice, MIESIĄC, ROK

Spis treści

1. Wstęp	1
1.1 Wprowadzenie teoretyczne	2
1.1.1 Ultrasonografia	2
1.1.2 Zastosowanie USG w kardiologii	5
1.1.3 Standard DICOM	7
1.1.4 Analiza obrazowa wspomagana komputerowo	7
1.2 Rozwiązania alternatywne	8
1.2.1 Segmentacja naczyń krwionośnych w obrazach USG	9
1.2.2 Pomiar naczyń krwionośnych	10
1.3 Cel pracy	10
1.4 Układ pracy	11
2. Metodologia	13
3. Część konstrukcyjna/Specyfikacja wewnętrzna	15
4. Instrukcja obsługi/Specyfikacja zewnętrzna	17
5. Rezultaty	19
6. Podsumowanie	21
 Dodatek	 23
A. Dodatek A	25
B. Dodatek B	27
B.1 Wstawianie rysunków	27
B.2 Wstawianie tabel	27
C. Kwestie edytorskie	29
Bibliografia	30

Spis rysunków

1.1	Schemat zjawiska piezoelektrycznego [24].	3
1.2	Zjawiska zachodzące po emisji fali USG [1].	3
1.3	Porównanie obrazowania mózgu za pomocą różnych metod: TK (a), MR (b), PET (c), SPECT (d), USG (e) [10].	5
1.4	Wizualizacja igły wkłuwanej do żyły szyjnej wewnętrznej w badaniu USG (przekrój poprzeczny). Czerwoną strzałką oznaczono końcówkę igły [29].	6
B.1	Logo Wydziału Inżynierii Biomedycznej.	28

Spis tabel

B.1 Opis nad tabelką.	28
-------------------------------	----

1. Wstęp

Postęp medycyny niewątpliwie z roku na rok staje się coraz większy. Takie działanie motywuje przede wszystkim chęć poprawy ogólnego zdrowia społeczeństwa, prowadząc do wydłużenia średniego życia ludzi jak i nierzadko zapobiegania przedwczesnej śmierci. Prowadzone są stale liczne badania mające na celu: szybkie stawianie diagnoz, klasyfikację nowo odkrytych chorób, rozwój coraz to skuteczniejszych i mniej inwazyjnych metod leczenia czy udoskonalanie metod profilaktyki, w tym wdrażanie szczepień zapobiegającym nowym jednostkom chorobowym. Istotna jest więc współpraca pomiędzy środowiskiem medycznym jak i naukowym w celu osiągnięcia coraz to lepszych rozwiązań.

Oprócz rozwoju medycyny, wiele obszarów życia ludzkiego stale dąży do polepszenia jego ogólnej jakości. Postęp cywilizacyjny niezwykle szybko dostarcza nam nowych rozwiązań technologicznych. Okazuje się, że współdziałanie z pozoru rozbieżnych dziedzin może przynieść bardzo dobre rezultaty. Takim przykładem może być medycyna i rozwój nowych technologii, które znajdują szerokie zastosowanie w profilaktyce i diagnostyce chorób (np. aparaty do diagnostyki obrazowej: USG– ultrasonografia, TK– tomografia komputerowa, MR– rezonans magnetyczny), planowaniu i nawigacji chirurgicznej [25] (np. systemy śledzące, okulary do rozszerzonej rzeczywistości VR (ang. *Virtual Reality*), wspomaganiu zabiegów chirurgicznych i rehabilitacji (np. ramiona robotów) projektowaniu i wytwarzaniu implantów (również z wykorzystaniem druku 3D) oraz monitorowaniu aktywności fizycznych i prowadzeniu zdrowego stylu życia (np. mobilne aplikacje oraz opaski sportowe) [23].

Niewątpliwie każdy z przytoczonych przykładów przynosi wiele korzyści. Należy jednak podkreślić, że wczesna diagnostyka chorób może mieć największe znaczenie w odniesieniu do przywrócenia zdrowia lub zachowania życia. Diagnostyka, nie licząc działań profilaktycznych, stanowi pierwszy i nierzadko decydujący krok prowadzący do całkowitego wyleczenia lub podtrzymania życia pacjenta. Diagnoza medyczna, w zależności od przypadku, może polegać na ocenie pojawiających się objawów, badań laboratoryjnych, badań obrazowych lub połączeniu kilku procedur. Etap ten jest bardzo ważny, biorąc pod uwagę czas potrzebny na określenie jednostki chorobowej oraz zgodność postawionej diagnozy z rzeczywistością.

Z biegiem czasu coraz częściej obserwuje się nowe rozwiązania wspierające diagnostykę obrazową. Mogą one polegać na segmentacji i/lub oceny danego regionu zainteresowania jako obszar zmieniony (lub nie) chorobowo. Możliwa jest również dokładniejsza klasyfikacja pod kątem ustalenia jednostki chorobowej lub szacowanie i analiza wielkości takich jak np. długość, średnica czy objętość obserwowanych struktur (np. naczyń krwionośnych, organów, kości). Czynnikiem motywującym wdrażanie takich systemów

jest przede wszystkim większa wydajność i dokładność automatycznych, wspomaganych komputerowo systemów w stosunku do samodzielnej diagnozy, opartej na wiedzy lekarskiej. Co więcej, zaletą takich rozwiązań jest pominięcie czynnika ludzkiego, który może doprowadzić do błędnych wniosków, zagrażających bezpośrednio zdrowiu i życiu pacjenta. Naturalnym jest nie dopuszczenie do pełnej automatyzacji w kwestii działań medycznych, jednak wsparcie takich narzędzi może przynieść ogrom korzyści. Systemy te mogą opierać się na klasycznych metodach przetwarzania obrazowego jak i wykorzystaniu sztucznej inteligencji AI (ang. *Artificial Intelligence*). W dalszej części pracy temat ten zostanie przybliżony [4, 7, 27].

1.1 Wprowadzenie teoretyczne

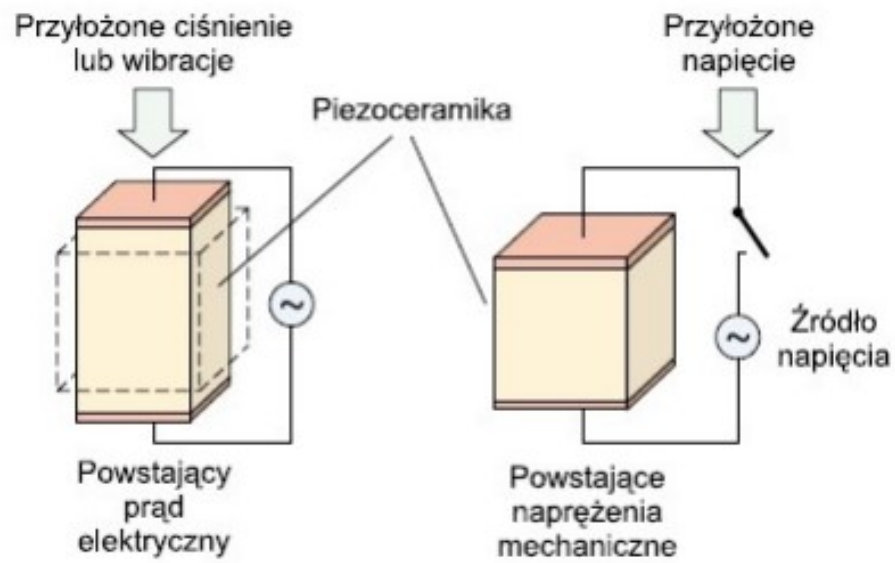
Wprowadzenie do tematyki pracy zostało podzielone sekcje dotyczące kolejno: zasady działania, przebiegu badania USG, zastosowania ultrasonografii oraz wykorzystania w przypadku obrazowania naczyń krwionośnych (1.1.1), kaniulacji żył obwodowych (1.1.2), diagnostyki obrazowej wspomaganej komputerowo (1.1.4), z podziałem na tradycyjne metody i te z wykorzystaniem AI oraz standardu DICOM (1.1.3). Na końcu została przybliżona tematyka określania wielkości naczyń krwionośnych na podstawie obrazów USG (1.2.2).

1.1.1 Ultrasonografia


Do badań obrazowych możemy zaliczyć przede wszystkim: USG, TK, MR, pozytonową tomografię emisyjną PET (ang. *Positron Emission Tomography*) oraz tomografię emisyjną pojedynczych fotonów SPECT (ang. *Single-Photon Emission Computed Tomography*). Każde z przytoczonych modalności podlega innej charakterystyce. W zależności sytuacji pacjenta dobiera się odpowiednie badanie.

Termin ultradźwięki (fale akustyczne) odnosi się do częstotliwości, które przekraczają 20 kHz. Jest to granica traktowana jako górna częstotliwość, jaką może usłyszeć ludzkie ucho. Zazwyczaj systemy ultradźwiękowe działają w zakresie częstotliwości od 2 MHz do 20 MHz. Badanie przeprowadza się przy użyciu specjalnej aparatury, która poprzez głowicę wysyła do wnętrza organizmu fale ultradźwiękowe. Powstają one dzięki zawartym w głowicy piezoelektrykom i odwrotnemu zjawisku piezoelektrycznym. Polega ono na zdolności kryształów piezoelektrycznych do odpowiadania na zadany sygnał elektryczny mechaniczną deformacją i tym samym wytwarzaniem fali mechanicznej (ultradźwiękowej). Te następnie odbijają się od badanych tkanek. Powracające fale trafiają spowrotem do głowicy, gdzie zachodzi proste zjawisko piezoelektryczne. W wyniku poddania niektórych kryształów mechanicznym naprężeniom (ściskaniu lub rozciąganiu) generowany zostaje potencjał elektryczny, który zostaje zmierzony i odpowiednio przetworzony (Rys. 1.1) [3, 24].

Podczas badania USG dochodzi do kilku zjawisk: odbicie, rozproszenie (opór akustyczny), tłumienie (osłabienie) oraz załamanie (refrakcja) (Rys. 1.2). Wykorzystanie zjawiska odbicia fali na granicy ośrodków o różnych gęstościach (różna prędkość rozcho-



Rys. 1.1: Schemat zjawiska piezoelektrycznego [24].



Rys. 1.2: Zjawiska zachodzące po emisji fali USG [1].

dzenia się fali) powoduje odbiór ultradźwięków w różnych odstępach czasu, co pozwala na ocenę wielkości, kształtu i struktury narządów, a w szczególności różnicowanie zmian o charakterze litym od zmian o charakterze płynowym. Do obrazowania wykorzystywana jest część odbita fali w postaci tzw. powracającego echa, które analizowane jest pod kątem położenia i intensywności. Po komputerowym przetworzeniu danych, na ekranie widoczne są punkty odpowiadające umiejscowieniom odbicia fal. Intensywności echa przyporządkowane są odpowiednim odcieniom ze skali szarości– od tonu najciemniejszego (kolor czarny) dla braku lub bardzo małej intensywności echa, do koloru białego odpowiadającego dużemu natężeniu [3].


Możemy wyróżnić 3 typy głowic USG:

- Liniowa– zawiera szereg elementów piezoelektrycznych ustawionych współliniowo. Otrzymany obraz jest obszarem prostokątnym. Głowice liniowe pozwalają uzyskać najdokładniejszy obraz.
- Sektorowa– elementy piezoelektryczne są umieszczone na obrotowym wirniku, co pozwala na zastosowanie mniejszej ich liczby. Głowice sektorowe charakteryzują się znacznie szerszym obszarem wiązki niż głowice liniowe, ale zazwyczaj dużo gorszymi parametrami rozdzielczości.
- Konweksowa– jest rozwiązaniem pośrednim między głowicą sektorową a liniową. Pozwala uzyskać znacznie dokładniejsze obrazy niż głowica sektorowa, a pole obserwacji jest dużo większe niż w przypadku głowicy liniowej [3].

Obrazowanie ultrasonograficzne to nieinwazyjna i tania metoda, dostarczająca wyników w czasie rzeczywistym w przeciwieństwie do pozostałych metod. Zapewnia wiele korzyści takich jak brak promieniowania jonizującego oraz zapewnia ciągłe obrazowanie wideo w czasie rzeczywistym. Dodatkową zaletą jest bezbolesność badania. Niestety USG posiada również kilka wad. Spośród wymienionych badań ultrasonografia jest jedną z najmniej dokładnych metod i podatną na szumy, objawiające się niewyraźnym obrazem [3, 6]. Na rysunku 1.3 przedstawiono zestawienie przykładowych obrazów poszczególnych metod obrazowania.

TK, MR, PET oraz SPECT dostarczają w jednym badaniu wiele obrazów przekrojowych 2D danej partii ciała. Taka seria daje większy i dokładniejszy ogłód na analizowany obszar organizmu. Co więcej umożliwia w dalszym przetwarzaniu przeprowadzenie modelu 3D np. badanego organu. W przypadku braku takiej konieczności często wyborem staje się właśnie USG. Istnieje jednak szansa na rekonstrukcję 3D również na podstawie obrazów USG, jednak wymaga to zastosowania w takcie procedury systemu śledzącego, które pozostaje niestety obarczone błędem. Innym sposobem może być mechaniczna manipulacja głowicą (przechylenie, obracanie lub liniowe przemieszczenie) uzyskując wiele skanów interesującego obszaru [3, 7, 12, 25].

Obrazowanie ultrasonograficzne pozwala uniknąć wysokich kosztów w przypadku MR, promieniowania w TK, oraz narażenie na potencjalnie szkodliwe środki kontrastowe. W związku z tym jest to jedyne tego typu badanie wykonywane kobietom w ciąży w celu oceny rozwoju płodu i nie tylko. USG jest wykorzystywane do analizy wielu




Rys. 1.3: Porównanie obrazowania mózgu za pomocą różnych metod: TK (a), MR (b), PET (c), SPECT (d), USG (e) [10].

narządów takich jak: mózg, serce, wątroba, nerki, macica i inne. Badanie to również znajduje zastosowanie w kardiologii do oceny naczyń krwionośnych (np. wykrywanie blaszek miażdżycowych) oraz jako kontrola obrazowa podczas procedur takich jak np. kaniulacja żył [12, 26].

1.1.2 Zastosowanie USG w kardiologii

USG z racji między innymi braku inwazyjności, niskich kosztów w stosunku do TK czy MR oraz rejestracji obrazów w czasie rzeczywistym stara się wykorzystywać na wielu polach diagnostyki medycznej. Jednym z nich jest badanie naczyń krwionośnych. Przykładem konkretnego zastosowania ultrasonografii w tym obszarze jest monitorowanie procedury kaniulacji. Pojęcie to odnosi się do nakłuwania naczyń krwionośnych, zarówno żył jak i tętnic (np. żyła szyjna IJV (ang. *Internal Jugular Vein*), żyła udowa FV (ang. *Femoral Vein*), tętnica udowa FA (ang. *Femoral Artery*) czy tętnica promieniowa RA (ang. *Radial Artery*)) (Rys. 1.4). Celem dostania się do światła naczynia krwionośnego jest przykładowo aplikacja znieczulenia lub podanie leków dożylnych. Niestety częstym powikłaniem są przypadkowe nakłucia sąsiedniego naczynia, powstawanie krwiaków w miejscach docelowych oraz odma opłucna. Aby zmniejszyć częstość tych niepowodzeń procedurę kaniulacji zaczęto przeprowadzać pod nadzorem ultrasonografii. Pozwala to na obserwację przekroju naczynia krwionośnego, położenia w stosunku do sąsiedniej tętnicy oraz śledzenie wbijanej igły. Segmentacja takich obrazów w czasie rzeczywistym z pewnością przyczynia się do jeszcze większej precyzji wykonującego nakłucie [17, 28, 29, 31, 32].

USG układu krwionośnego może być również wykorzystywane nie tylko w celach



Rys. 1.4: Wizualizacja igły wkłuwanej do żyły szyjnej wewnętrznej w badaniu USG (przekrój poprzeczny). Czerwoną strzałką oznaczono końcówkę igły [29].

diagnostycznych, ale również do planowania zabiegów chirurgicznych takich jak endarterektomia tętnic szyjnych CEA (ang. *Carotid Endarterectomy*). Jest to uznana metoda leczenia miażdżycy tętnicy szyjnej i polega ona na operacyjnym usunięciu, a dokładnie wycięciu blaszek miażdżycowych ze światła naczynia. Powstająca wewnątrz tętnicy blaszka miażdżycowa skutkuje zwężeniem, a nawet zamknięciem jej światła. Miażdżycza tętnic szyjnych jest poważną przyczyną wystąpienia udaru niedokrwionego mózgu. W związku z tym endarterektomia na wczesnych etapach miażdżycy staje się skuteczną formą leczenia. Aby przeprowadzić taki zabieg istotna jest bardzo dokładna lokalizacja blaszek ze względu na ich niewielkie wymiary oraz możliwość uszkodzenia wrażliwej struktury jaką jest tętnica. Dzięki USG przedoperacyjnemu można dostatecznie określić miejsca występujących zmian i odpowiednio zaplanować proces operacji. Wspomagającym rozwiązaniem stają się systemy dokonujące segmentacji naczyń wraz z blaszkami miażdżycowymi. Dzięki temu można określić ich wielkość (np. długość, objętość w przypadku rekonstrukcji 3D) oraz pole przekroju ograniczonego światła tętnicy w danym miejscu, a następnie po przeprowadzonej endarterektomii dokonać analizy porównawczej z uzyskanymi rezultatami [8, 13, 21].

Analizę stanu naczyń krwionośnych wykonuje się również stosując różne modalności standardowego USG. Przykładem może być USG Doppler, polegające na obserwowaniu przepływu krwi. Ultrasonografia Dopplerowska wykorzystuje rozproszenie fali dźwiękowej na poruszającym się obiekcie (np. przepływających w naczyniach krwinkach), dzięki czemu pozwala na zdobycie informacji o prędkości z jaką przemieszcza się obserwowany obiekt. Na tej podstawie można dokonać oceny, w których miejscach przepływ krwi jest wolniejszy oraz gdzie przepływ jest zablokowany. W jednym z rodzajów badania z wykorzystaniem zjawiska Dopplera obserwować można kolorystykę poruszających się szybko obiektów odpowiednią w zależności od kierunku przepływu. Elementy statyczne pozostają w odcieniach szarości. W wyniku analizy tętnic i żył przy użyciu tej techniki, można obliczyć maksymalną wartość prędkości lub objętość krwi przepływającą przez naczynie przypadającą na jednostkę czasu [29, 31, 32].

Inną odmianą klasycznego USG jest wewnątrznacyniowe obrazowanie ultradźwiękami IVUS (ang. *Intravascular Ultrasound*). Technika ta polega na wytworzeniu obrazów przekrojów poprzecznych podczas prowadzenia cewnika wewnątrz naczyń krwionośnych. Dzięki temu można zaobserwować światło naczyń jak i strukturę ścian nacyniowej. W ostatnich latach technologia ta stała się bardzo przydatna w analizie choroby miażdżycowej. Zapewnia informację o charakterze zmiany miażdżycowej oraz kształcie i wielkości blaszki miażdżycowej. Zbadano również inne zastosowanie IVUS jakim stała się implantacja stentów. Automatyczne rozwiązania do segmentacji ścian naczyń oraz analizy blaszek miażdżycowych pozwalają na uzyskanie większej dokładności oraz podejmowania szybszych działań w obliczu diagnozy i leczenia pacjentów [5].

1.1.3 Standard DICOM

Rozwój sprzętu przeznaczonego do obrazowania medycznego, wdrażanych do użytku przez różnych producentów, wymusił opracowanie standardu przechowywania i wymiany obrazów medycznych. Dzięki wprowadzeniu wzorca DICOM (ang. *Digital Imaging and Communication in Medicine*). Wymiana obrazów medycznych stała się łatwiejsza, szybsza i bezpieczniejsza pomiędzy systemami informatycznych (np. RIS (ang. *Radiology Information System*), PACS (ang. *Picture Archiving and Communication System*)). Aktualna wersja (3.0) została opublikowana przez NEMA (ang. *National Electrical Manufacturers Association*) w 1993 roku. Oprócz podstawowych danych obrazowych format takiego pliku (.dicom) przechowuje przydatne metadane takie jak: dane pacjenta, dane jednostki wykonującej badanie, datę, rodzaj badania, informacje dotyczące cech obrazu oraz wiele innych. Standard DICOM posiada ważną zaletę – umożliwia dalszą rozbudowę i aktualizację stale rozwijających się modułów. Z punktu widzenia szybkiego postępu w dziedzinie obrazowania jest to bardzo przydatna cecha [18, 20].

1.1.4 Analiza obrazowa wspomagana komputerowo

Postęp technologiczny aparatury przeznaczonej do obrazowania medycznego zapewnia coraz lepszą jakość uzyskiwanych obrazów. Dzięki wysokiej rozdzielczości możliwe staje się projektowanie automatycznych systemów przeznaczonych do analizy medycznej, niejednokrotnie przewyższających możliwości ekspertów. Takie rozwiązania można podzielić na klasyczne oraz te z użyciem sztucznej inteligencji.

Przetwarzanie obrazów jest szerokim pojęciem, obejmującym wiele różnych metod mających na celu analizę lub/ oraz modyfikację cech obrazowych w celu poprawy jego parametrów lub poszukiwania określonych wzorców. Przykładem może być wykrywanie tekstur, kształtów, czy konturów. W tym obszarze zastosowanie nierzadko znajdują filtry (często stosowane do ogólnej poprawy jakości), mające na celu wyeksponowanie danych struktur w obrazie np. krawędzi (filtr Canny’ego, Laplace’a). Przydatne są również operacje morfologiczne, dzięki którym możliwa jest modyfikacja cech geometrycznych obiektów. Bardzo wartościowym na wielu polach zabiegiem jest proces segmentacji. Polega on na podziale obrazu na regiony (zbiory pikseli) podobne względem

siebie według pewnych przyjętych własności np. poziomy szarości. Istnieje wiele metod klasycznych wykorzystywanych do segmentacji poszukiwanych obiektów w obrazie. Są nimi: progowanie (np. Otsu), rozrost i/lub podział obszaru, dopasowanie wzorca lub metody krawędziowe np. aktywny kontur (ang. *active contour*). Innym obszarem z zakresu przetwarzania obrazowego jest klasyfikacja na przykład poprzez grupowanie lub z użyciem metod statystycznych [9].

Zupełnie inaczej do analizy obrazowej odnosi się pojęcie sztucznej inteligencji. Termin AI jest stosowany, chcąc zdefiniować proces naśladowania funkcji poznawczych takich jak uczenie się i rozwiązywanie problemów. Innymi słowy sztuczna inteligencja to systemy, realizujące zadania, które zwykle wymagają ludzkiej inteligencji. W obszarze AI możemy wyróżnić pojęcie uczenia maszynowego ML (ang. *Machine Learning*), które oznacza uczenie się na podstawie dostarczonych danych bez wyraźnego zaprogramowania. Przykładami takich rozwiązań są: analiza głównych składowych PCA (ang. *principal component analysis*), maszyna wektorów nośnych SVM (*support vector machines*) oraz sztuczne sieci neuronowe ANN (ang. *artificial neural networks*). Architektura sieci neuronowej składa się z warstw, złożonych z połączonych ze sobą neuronów. Każdy neuron wykonuje ważoną sumę danych wejściowych, które są następnie przekazywane do funkcji aktywacji. Wagi są dobierane dynamicznie na etapie treningu. Można wyróżnić następujące typy warstw: warstwa wejściowa (przyjmuje dane wejściowe), warstwa wyjściowa (dostarcza wyniki przetwarzania danych) i warstwa ukryta (wyodrębnia cechy analizowanych danych). Najnowsze osiągnięcia dotyczą podzbioru ML, jakim jest głębokie uczenie DL (ang. *Deep Learning*). Są to metody uczenia oparte na sieciach neuronowych, które dokonują samodzielnego uczenia, poprzez rozpoznawanie wzorców z zastosowaniem wielu warstw przetwarzania. Spośród różnych rozwiązań głębokiego uczenia splotowe sieci neuronowe CNN (ang. *Convolution Neural Network*) można uznać za wysoko cenione i wykorzystywane w wielu dziedzinach życia ludzkiego. CNN są niezwykle cennym narzędziem w zakresie analizy obrazowej, szczególnie w zakresie medycznym [16, 22, 30].

1.2 Rozwiązania alternatywne

Ze względu na specyfikę tematu pracy i brak dostępnych rozwiązań realizujących w całości temat niniejszej pracy przegląd alternatywnych metod podzielono na dwa obszary— segmentacja naczyń krwionośnych w obrazach ultrasonograficznych oraz pomiar naczyń krwionośnego na podstawie wcześniej uzyskanej maski. Dodatkowym argumentem przemawiającym za takim podziałem pracy jest możliwość wykorzystywania obrazów segmentacyjnych do różnych zastosowań. Maski struktur czy obiektów anatomicznych są wartościowymi danymi, pozwalającymi na dalszą i głębszą analizę w konkretnym obszarze.

1.2.1 Segmentacja naczyń krwionośnych w obrazach USG

Problem segmentacji danych obiektów na obrazie można podzielić na dwie podstawowe grupy: metody klasyczne oraz metody opierające się na uczeniu maszynowym. Przykładem rozwiązań pierwszego typu jest użycie transformaty Hough'a (ang. *Hough Transform*), która wykrywa regularne kształty np. okręgi (kształt naczyń w widoku przekrojowym obrazu ultrasonograficznego jest najbardziej zbliżony do okręgu). Opiera się na wyznaczeniu prawdopodobieństwa wystąpienia danego obiektu w każdym punkcie obrazu. Takie podejście zaproponowali: Spyretta Golemati, John Stoitisis, Emmanouil G. Sifakis, Thomas Balkizas oraz Konstantina S. Nikita w pracy zatytułowanej „*Using the hough transform to segment ultrasound images of longitudinal and transverse sections of the carotid artery*” [11]. Inną technikę wykorzystali autorzy pracy o tytule „*Ultrasound Common Carotid Artery Segmentation Based on Active Shape Model*” [34], w której to opisali wykrywanie granic ściany naczynia krwionośnego z zastosowaniem modeli aktywnych kształtów (ang. *Active Shape Models*). Metoda polega na statystycznym dopasowaniu kształtu wejściowego do obiektu zainteresowania poprzez iteracyjne odkształcanie. Ciekawe rozwiązanie przedstawili Amr R. Abdel-Dayem i Mahmoud R. El-Sakka w pracy „*Carotid Artery Ultrasound Image Segmentation Using Fuzzy Region Growing*” [2], gdzie na podstawie punktu startowego przeprowadzony jest algorytm wzrostu rozmytego regionu (ang. *Fuzzy Region Growing*). Jego wynikiem jest rozmyta mapa połączeń, która zostaje poddana progowaniu.

Istnieje wiele innych klasycznych technik, pozwalających wykryć kontur i uzyskać maskę segmentowanego naczynia. Mimo niezbyt skomplikowanej implementacji takich algorytmów są one nierzadko półautomatyczne, co oznacza, że konieczna jest ingerencja użytkownika, najczęściej na początkowym etapie procesu (np. poprzez wybór punktu początkowego, należącego do obiektu). W związku z tym wyniki są mocno zależne od dokładności działań człowieka. Kolejną wadą tego typu strategii jest znaczny wpływ jakości obrazu (np. obecność szumu, artefaktów, kontrast), którą nie zawsze da się skorygować w wystarczającym stopniu, na działanie algorytmu. Upraszczając, można stwierdzić, że mając do czynienia z gorszym jakościowo obrazem należy liczyć się z mniej dokładnym wynikiem. Niektóre z tych metod są kosztowne obliczeniowo i tym samym czasochłonne. Biorąc pod uwagę powyższe argumenty oraz kwestię ciągłego rozwoju i badań nad rewolucyjnymi, w pełni automatycznymi i szeroko stosowanymi metodami z zakresu uczenia maszynowego, postanowiono dokonać przeglądu alternatywnych działań właśnie w tym zakresie.

W pracy „*Automatic localization of Common Carotid Artery in ultrasound images using Deep Learning*” [14] zaproponowano podejście wykrywania tętnicy szyjnej CCA (ang. *Common Carotid Artery*) w obrazach ultrasonograficznych z wykorzystaniem szybkiej rekurencyjnej splotowej sieci neuronowej (ang. *Faster R-CNN*), aby wykryć prostokątny region zainteresowania (ang. *Object bounding box*), zawierający CCA. Następnie przeprowadzono kilka różnych technik lokalizacyjnych (np. aktywny kontur), aby dokładnie wyznaczyć granicę tętnicy. Współczynnik Jaccarda'a, w odniesieniu do obrazów prawdy (ang. *ground truth*), wyniósł około 0,91. Na takich wynikach w łatwy

sposób można uzyskać maski analizowanych obiektów.

Inne podejście przedstawia artykuł „*Deep learning methods for detection of carotid artery wall*” [19], w którym to autorzy podejmują zadanie segmentacji CCA przy pomocy sieci CNN SegNet i porównują wyniki ze zmodyfikowaną głęboką siecią konwulucyjną opartą na modelu U-Net. Zaproponowane rozwiązanie (CNN SegNet) osiągnęło nieco lepszy wynik, plasujący się na poziomie 0,92 wg. wskaźnika Dice’a.

W kolejnej z pracy o tytule „*Two-stage and dual-decoder convolutional U-Net ensembles for reliable vessel and plaque segmentation in carotid ultrasound images*” [33] wykorzystano zmodyfikowany model sieci U-Net do przygotowania dwóch metod—dwuetapowego kaskadowego połączenia U-Net oraz podwójnego dekodera U-Net. Pierwsza z nich osiągnęła wskaźnik Dice’a wynoszący 0,95, natomiast druga 0,91.

Publikacja pt. „*Segmentation of common and internal carotid arteries from 3D ultrasound images based on adaptive triple loss*” [15] prezentuje metodę segmentacji CCA za pomocą dwukanałowej sieci U-Net. Zastosowano podejście z trzykrotną segmentacją na podstawie wejściowych obrazów ich odwróconych wersji. Ostateczna maska segmentacji została wygenerowana poprzez tzw. głosowanie większościowe. Uzyskane przez autorów wyniki w postaci wskaźnika Dice’a wynoszą 95%.

Leah A. Groves, Blake VanBerlo, Natan Veinberg, Abdulrahman Alboog, Terry M. Peters oraz Elvis C. S. Chen w swojej pracy „*Automatic segmentation of the carotid artery and internal jugular vein from 2D ultrasound images for 3D vascular reconstruction*” [12] porównują sieć Mask R-CNN oraz U-Net oparte na algorytmach automatycznego segmentowania tętnicy szyjnej i żyły szyjnej wewnętrznej w obrazach ultrasonograficznych. Do szkolenia obydwu modeli zastosowano czterokrotną walidację krzyżową. Algorytm U-Net zawierał dodatkowo etap przetwarzania końcowego, w który ostateczną segmentację stanowił największy połączony obszar dla każdej klasy (CCA oraz IJV). Mask R-CNN jest z kolei rozbudowaną wersją szybkiej rekurencyjnej splotowej sieci neuronowej (Faster R-CNN), jednak oprócz dostarczenia dwóch wyjściowych danych tj. *Object bounding box* oraz klasy obiektu, sieć przekazuje również wynik segmentacji tego obiektu. Zawiera ona kilka sieci składowych w tym m.in. ResNet-50. Średnie wyniki segmentacji dla CCA i IJV, na podstawie wskaźnika Dice’a uzyskane przez maskę R-CNN wyniosły 0,90 i 0,88 odpowiednio. Zmodyfikowana końcowo sieć U-Net osiągnęła wynik na poziomie 0,81 oraz 0,71 dla CCA i IJV.

1.2.2 Pomiar naczynia krwionośnego

Każde z przytoczonych rozwiązań skutkuje różnymi rezultatami, a odpowiedni wybór powinien być dostosowany do danego problemu.

1.3 Cel pracy

Celem pracy jest stworzenie automatycznego systemu mającego za zadanie określenie wielkości naczyń krwionośnych w obrazach ultrasonograficznych. Wymaga to realizacji następujących etapów:

- zebranie danych– rejestracja obrazów ultrasonograficznych naczyń krwionośnych oraz przegląd otwarto-źródłowych baz obrazów,
- przegląd dostępnych rozwiązań i wybór narzędzi,
- opracowanie algorytmu segmentacji naczyń krwionośnych z obrazów USG,
- opracowanie metody pomiaru wielkości naczynia krwionośnego na podstawie segmentacji,
- testowanie systemu.

1.4 Układ pracy

2. Metodologia

3. Część konstrukcyjna/Specyfikacja wewnętrzna

4. Instrukcja obsługi/Specyfikacja zewnętrzna

5. Rezultaty

6. Podsumowanie

Dodatek

Bibliografia

- [1] SPARQ New Way of Thinking1. 2 OCZEKIWANIA Intensive care/RA Mobilność aparatu USG Łatwość i intuicyjność użycia aparatu USG Pewność diagnostyczna. - ppt pobierz. <https://slideplayer.pl/slide/811173/>. [data dostępu: 2021-11-28].
- [2] ABDEL-DAYEM, A. R., AND EL-SAKKA, M. R. Carotid Artery Ultrasound Image Segmentation Using Fuzzy Region Growing. In *Image Analysis and Recognition*, D. Hutchison, T. Kanade, J. Kittler, J. M. Kleinberg, F. Mattern, J. C. Mitchell, M. Naor, O. Nierstrasz, C. Pandu Rangan, B. Steffen, M. Sudan, D. Terzopoulos, D. Tygar, M. Y. Vardi, G. Weikum, M. Kamel, and A. Campilho, Eds., vol. 3656. Springer Berlin Heidelberg, Berlin, Heidelberg, 2005, pp. 869–878.
- [3] ALI, M., MAGEE, D., AND DASGUPTA, U. Signal processing overview of ultrasound systems for medical imaging. *SPRAB12, Texas Instruments, Texas* (2008).
- [4] AMISHA, MALIK, P., PATHANIA, M., AND RATHAUR, V. Overview of artificial intelligence in medicine. *Journal of Family Medicine and Primary Care* 8, 7 (2019), 2328.
- [5] CARDINAL, M.-H., MEUNIER, J., SOULEZ, G., MAURICE, R., THERASSE, E., AND CLOUTIER, G. Intravascular ultrasound image segmentation: A three-dimensional fast-marching method based on gray level distributions. *IEEE Transactions on Medical Imaging* 25, 5 (May 2006), 590–601.
- [6] CHE, C., MATHAI, T. S., AND GALEOTTI, J. Ultrasound registration: A review. *Methods* 115 (Feb. 2017), 128–143.
- [7] CHEN, J. H., AND ASCH, S. M. Machine Learning and Prediction in Medicine — Beyond the Peak of Inflated Expectations. *New England Journal of Medicine* 376, 26 (June 2017), 2507–2509.
- [8] CHENG, J., CHEN, Y., YU, Y., AND CHIU, B. Carotid plaque segmentation from three-dimensional ultrasound images by direct three-dimensional sparse field level-set optimization. *Computers in Biology and Medicine* 94 (Mar. 2018), 27–40.
- [9] DOUGHERTY, E. R. *Digital Image Processing Methods*. CRC Press, Aug. 2020.

- [10] EL-GAMAL, F. E.-Z. A., ELMOGY, M., AND ATWAN, A. Current trends in medical image registration and fusion. *Egyptian Informatics Journal* 17, 1 (Mar. 2016), 99–124.
- [11] GOLEMATI, S., STOITSIS, J., SIFAKIS, E. G., BALKIZAS, T., AND NIKITA, K. S. Using the Hough Transform to Segment Ultrasound Images of Longitudinal and Transverse Sections of the Carotid Artery. *Ultrasound in Medicine & Biology* 33, 12 (Dec. 2007), 1918–1932.
- [12] GROVES, L. A., VANBERLO, B., VEINBERG, N., ALBOOG, A., PETERS, T. M., AND CHEN, E. C. S. Automatic segmentation of the carotid artery and internal jugular vein from 2D ultrasound images for 3D vascular reconstruction. *International Journal of Computer Assisted Radiology and Surgery* 15, 11 (Nov. 2020), 1835–1846.
- [13] HASSAN, M., MURTZA, I., HIRA, A., ALI, S., AND KIFAYAT, K. Robust spatial fuzzy GMM based MRI segmentation and carotid artery plaque detection in ultrasound images. *Computer Methods and Programs in Biomedicine* 175 (July 2019), 179–192.
- [14] HASSANIN, D., ABDELLAH, M., KHALAF, A., AND GHARRIEB, R. R. Automatic localization of Common Carotid Artery in ultrasound images using Deep Learning. *Journal of Advanced Engineering Trends* 40, 2 (July 2021), 127–135.
- [15] JIANG, M., ZHAO, Y., AND CHIU, B. Segmentation of common and internal carotid arteries from 3D ultrasound images based on adaptive triple loss. *Medical Physics* 48, 9 (Sept. 2021), 5096–5114.
- [16] KIM, M., YAN, C., YANG, D., WANG, Q., MA, J., AND WU, G. Deep learning in biomedical image analysis. In *Biomedical Information Technology*. Elsevier, 2020, pp. 239–263.
- [17] MAECKEN, T., AND GRAU, T. Ultrasound imaging in vascular access:. *Critical Care Medicine* 35, Suppl (May 2007), S178–S185.
- [18] MILDENBERGER, P., EICHELBERG, M., AND MARTIN, E. Introduction to the DICOM standard. *European Radiology* 12, 4 (Apr. 2002), 920–927.
- [19] MILOS ANIC, BRANKO ARSIC, S. D. N. F. Deep learning methods for detection of carotid artery wall. *Ri-STEM-2021* (2021), 135.
- [20] MUSTRA, M., DELAC, K., AND GRGIC, M. Overview of the DICOM Standard. *th International Symposium ELMAR* (2008), 6.
- [21] NORRIS, J. W., AND HALLIDAY, A. Is Ultrasound Sufficient for Vascular Imaging Prior to Carotid Endarterectomy? *Stroke* 35, 2 (Feb. 2004), 370–371.

- [22] PESAPANE, F., CODARI, M., AND SARDANELLI, F. Artificial intelligence in medical imaging: Threat or opportunity? Radiologists again at the forefront of innovation in medicine. *European Radiology Experimental* 2, 1 (Dec. 2018), 35.
- [23] PHILLIPS, S. A., ALI, M., MODRICH, C., OKE, S., ELOKDA, A., LADDU, D., AND BOND, S. Advances in Health Technology Use and Implementation in the Era of Healthy Living: Implications for Precision Medicine. *Progress in Cardiovascular Diseases* 62, 1 (Jan. 2019), 44–49.
- [24] ROSZKOWSKI, M. System do pomiaru odpowiedzi czestotliwosciowej piezoelektrykow z procesorem wbudowanym w ukklad programowalny. Master’s thesis, Politechnika Warszawska, Warszawa, 2015.
- [25] SAKAS, G. Trends in medical imaging: From 2D to 3D. *Computers & Graphics* 26, 4 (Aug. 2002), 577–587.
- [26] SCOUTT, L. M., AND GUNABUSHANAM, G. Carotid Ultrasound. *Radiologic Clinics of North America* 57, 3 (May 2019), 501–518.
- [27] SHEN, Y.-T., CHEN, L., YUE, W.-W., AND XU, H.-X. Artificial intelligence in ultrasound. *European Journal of Radiology* 139 (June 2021), 109717.
- [28] SMISTAD, E., AND LINDSETH, F. Real-Time Automatic Artery Segmentation, Reconstruction and Registration for Ultrasound-Guided Regional Anaesthesia of the Femoral Nerve. *IEEE Transactions on Medical Imaging* 35, 3 (Mar. 2016), 752–761.
- [29] ŠPAČEK, R., JIRAVSKÝ, O., NEUWIRTH, R., HOLEK, B., ŠKŇOURIL, L., HEČKO, J., AND BRANNY, M. Use of ultrasound guidance in vascular cannulation and effusion punctures at the cardiology department. *Cor et Vasa* 60, 3 (June 2018), e306–e313.
- [30] TANG, X. The role of artificial intelligence in medical imaging research. *BJR—Open* 2, 1 (Nov. 2020), 20190031.
- [31] TROIANOS, C. A., HARTMAN, G. S., GLAS, K. E., SKUBAS, N. J., EBERHARDT, R. T., WALKER, J. D., AND REEVES, S. T. Guidelines for Performing Ultrasound Guided Vascular Cannulation: Recommendations of the American Society of Echocardiography and the Society of Cardiovascular Anesthesiologists. *Journal of the American Society of Echocardiography* 24, 12 (Dec. 2011), 1291–1318.
- [32] WORLD HEALTH ORGANIZATION. *IMAI District Clinician Manual: Hospital Care Adolescents and Adults : Guidelines for the Management of Illnesses with Limited-Resources*. World Health Organization, Geneva, 2012.

- [33] XIE, M., LI, Y., XUE, Y., HUNTRESS, L., BECKERMAN, W., RAHIMI, S. A., ADY, J. W., AND ROSHAN, U. W. Two-stage and dual-decoder convolutional U-Net ensembles for reliable vessel and plaque segmentation in carotid ultrasound images. In *2020 19th IEEE International Conference on Machine Learning and Applications (ICMLA)* (Miami, FL, USA, Dec. 2020), IEEE, pp. 1376–1381.
- [34] YANG, X., JIN, J., XU, M., WU, H., HE, W., YUCHI, M., AND DING, M. Ultrasound Common Carotid Artery Segmentation Based on Active Shape Model. *Computational and Mathematical Methods in Medicine 2013* (2013), 1–11.